

18-11-2021

REGRESION LINEAL MULTIPLE

CMAS00 1.2.1



KEVIN ADRIAN CRUZ JACOBO
CDIA 301 COANLEP

Desripcion del dataset Boston

Predecir el valor de viviendas en Boston a partir de 13 variables independientes

	Variables independientes					Variable dependiente
	LSTAT	RM	NOX	TAX	DIS	MEDV
0	4.98	6.575	0.538	296.0	4.0900	24.0
1	9.14	6.421	0.469	242.0	4.9671	21.6
2	4.03	7.185	0.469	242.0	4.9671	34.7
3	2.94	6.998	0.458	222.0	6.0622	33.4
4	5.33	7.147	0.458	222.0	6.0622	36.2

- Cargamos los datos (506)
- Seleccionamos las variables para el modelo
- Dividimos los datos Train/Test
- Definimos el modelo
- Ajuste y prueba

$$\text{MEDV} = 13.634 - 0.700 \times \text{LSTAT} + 4.476 \times \text{RM} - 6.505 \times \text{NOX} - 0.0076 \times \text{TAX} - 0.968 \times \text{DIS}$$

$$\epsilon^T \epsilon = 4.76$$

$$R^2 = 0.71$$

Fundamentación

Modelo de abstracción que representa la relación entre una variable dependiente Y_i (regresando) y otras variables explicativas independientes X_{ji} (regresores)

Se asume que las observaciones satisfacen una relación lineal

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_p x_{pi} + \epsilon_i$$

- Supongamos un conjunto de N observaciones en un modelo lineal P variables independientes

observación

Variables explicativas

$\{x_{11}, x_{21}, x_{31}, \dots, x_{p1}, y_1\}$

$\{x_{12}, x_{22}, x_{32}, \dots, x_{p2}, y_2\}$

$\{x_{13}, x_{23}, x_{33}, \dots, x_{p3}, y_3\}$

\vdots

$\{x_{1n}, x_{2n}, x_{3n}, \dots, x_{pn}, y_n\}$

$y_1 = \beta_0 + \beta_1 x_{11} + \beta_2 x_{21} + \dots + \beta_p x_{p1} + \epsilon_1$

$y_2 = \beta_0 + \beta_1 x_{12} + \beta_2 x_{22} + \dots + \beta_p x_{p2} + \epsilon_2$

$y_3 = \beta_0 + \beta_1 x_{13} + \beta_2 x_{23} + \dots + \beta_p x_{p3} + \epsilon_3$

\vdots

$y_n = \beta_0 + \beta_1 x_{1n} + \beta_2 x_{2n} + \dots + \beta_p x_{pn} + \epsilon_n$

Función objetivo

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_p x_{pi} + \varepsilon_i$$

Representación en algebra matricial

$$Y = X\beta + \varepsilon$$

Diagram showing the matrix representation of the linear regression model. The equation $Y = X\beta + \varepsilon$ is shown with arrows pointing to the dimensions of each matrix:

- Y is an $n \times 1$ column vector: $\begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_n \end{bmatrix}$
- X is an $n \times (p+1)$ matrix: $\begin{bmatrix} 1 & x_{11} & x_{21} & x_{31} & \dots & x_{p1} \\ 1 & x_{12} & x_{22} & x_{32} & & x_{p2} \\ 1 & x_{13} & x_{23} & x_{33} & & x_{p3} \\ & & \vdots & & & \\ 1 & x_{1n} & x_{2n} & x_{3n} & & x_{pn} \end{bmatrix}$
- β is a $(p+1) \times 1$ column vector: $\begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_n \end{bmatrix}$
- ε is an $n \times 1$ column vector: $\begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \\ \vdots \\ \varepsilon_n \end{bmatrix}$



$$\min \sum_{i=1}^n \varepsilon_i^2 = \min(\varepsilon^T \varepsilon)$$

Minimizar la suma de los cuadrados de los errores

$$Y = X\beta + \varepsilon \begin{cases} \varepsilon = Y - X\beta \\ \varepsilon^T = (Y - X\beta)^T \end{cases}$$

$$\varepsilon^T \varepsilon = (Y - X\beta)^T (Y - X\beta)$$

$$\varepsilon^T \varepsilon = (Y^T - (X\beta)^T) (Y - X\beta)$$

$$\varepsilon^T \varepsilon = (Y^T - \beta^T X^T) (Y - X\beta)$$

$$\varepsilon^T \varepsilon = Y^T Y - Y^T X \beta - \beta^T X^T Y + \beta^T X^T X \beta$$

$$L(\beta) = Y^T Y - 2Y^T X \beta + \beta^T X^T X \beta$$



$$\min \sum_{i=1}^n \varepsilon_i^2 = \min(\varepsilon^T \varepsilon)$$

Minimizar la suma de los cuadrados de los errores

Gradiente



$$\min \sum_{i=1}^n \epsilon_i^2 = \min(\epsilon^T \epsilon)$$

Minimizar la suma de los cuadrados de los errores

$$L(\beta) = Y^T Y - 2Y^T X \beta + \beta^T X^T X \beta$$



$$Y = X\beta + \epsilon \quad \begin{cases} \epsilon = Y - X\beta \\ \epsilon^T = (Y - X\beta)^T \end{cases}$$

$$\frac{\partial L}{\partial \beta} = -2X^T Y + 2X^T X \beta = 0$$


$$X^T X \beta = X^T Y$$

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$



La estimación de mínimos cuadrados satisface esta expresión

Predicciones y error



Supongamos un conjunto de datos de prueba (Y_{TEST} , - X_{TEST})
 Supongamos también un modelo determinado $\beta = (X^T X)^{-1} X^T Y$
 Entonces el error de predicción sería $\epsilon = Y_{\text{test}} - X_{\text{test}} \beta$

$$\epsilon^t \epsilon$$